

语义分割和强化学习在自动驾驶中的应用综述

王婧怡, 孙从众, 任鹏飞, 梁亚琦

摘要

基于深度学习和强化学习的自动驾驶技术目前进展迅速, 同时也得到越来越多的关注。但是, 目前高级的自动驾驶功能仍然处在研究之中, 且现有的自动驾驶汽车也常常引起诸多争议。本文通过查阅多篇研究文献资料, 总结当前的各种语义分割算法和强化学习算法, 并分析了它们在自动驾驶各个方面(环境感知、决策制定、运动规划、车辆控制)的应用。同时, 我们结合过去的综述与现有的研究论文, 总结语义分割和强化学习在当前的研究和应用中仍未解决的问题, 为未来的自动驾驶研究人员提供指导。

关键词: 自动驾驶汽车 (AVs); 语义分割 (SS); 强化学习 (RL); 人工智能应用

Abstract

Deep learning and reinforcement learning-based autonomous driving technology is advancing rapidly and gaining more and more attention. However, advanced self-driving features are still under research and existing self-driving cars are often controversial. In this paper, we summarize various current semantic segmentation algorithms and reinforcement learning algorithms by reading several research papers and analyze their applications in various aspects of autonomous driving (environment understanding, decision making, motion planning, vehicle control). At the same time, we combine past reviews with existing research papers to summarize the still unresolved issues of semantic segmentation and reinforcement learning in current research and applications, and provide guidance for future autonomous driving researchers.

Keywords: Autonomous vehicles (AVs); semantic segmentation (SS); deep learning (RL); artificial intelligence application

1 绪论

自动驾驶车辆 (autonomous vehicles, 缩写 AVs, 或 self-driving vehicles) 指的是不需要人为、可以自主控制、自主驾驶的车辆。最高级的自动驾驶汽车可以不需要安装方向盘、油门等传统人为机械结构, 完全由计算机控制车辆的行驶。如同其他技术革命一样, 自动驾驶会带来许多产业的巨大革命, 也会对我们社会生活的方方面面产生影响。因此, 自动驾驶技术的进展和应用已经成为学术界、工业界和社会关注的热点之一。

自动驾驶的高速发展, 离不开计算机科学的巨大进展。随着深度学习和强化学习技术的深入研究, 以及以 NVIDIA 为代表的显卡计算能力越来越强, 许多传统无法解决的人工智能问题, 如人脸识别、物体检测、机器翻译、语音识别等问题, 随着深度神经网络 (deep neural network, DNN) 的推广和使用, 准确率达到大幅度提升, 很多已经达到应用水平, 可以广泛应用于工业和生活。同样地, 许多基于强化学习的 AI, 例如围棋、国际象棋的 AI, 能力也已远远超越人类水平。

此前, 许多研究已经对语义分割、强化学习、自动驾驶等几个方面进行综述。Galvao et al. 综述了自动驾驶中车辆和行人的检测识别方法; Elallid et al. 详细总结了深度学习和强化学习在自动驾驶中的应用和作用; Ahangar et al. 则总结了自动驾驶汽车的信息交流和通信问题。多篇论文从不同角度总结了自动驾驶与人工智能的现状。

我们的文章在此基础上，进一步展开讲解语义分割和强化学习在自动驾驶中的作用，具体分析语义分割在自动驾驶中的应用现状，讨论现有论文自动驾驶应用中出现的新思路，并且总结现有的问题和未来的研究方向。

接下来的文章内容如下：在第 2 章，我们简单介绍了自动驾驶、语义分割、强化学习的基础知识；在第 3 和第 4 章，我们分别介绍了近几年来语义分割和强化学习在自动驾驶的研究方向和应用；在第 5 章，我们讨论了现有研究出现的问题并指出未来潜在的研究方向；最后，在第 6 章我们总结了本论文综述的内容。

2 自动驾驶、语义分割、强化学习简介

2.1 自动驾驶

2.1.1 自动驾驶的分类

国际汽车工程师协会 (Society of Automotive Engineers, 缩写 SAE) 将自动驾驶分为六类，记为 L0 – L5，是目前在行业上应用广泛的一种分类标准。SAE 的自动驾驶标准中，数字越大代表自动驾驶等级越高。各个等级的简单解释如下：

- L0 代表汽车完全没有自动驾驶能力，需要人类全程控制驾驶。这类车辆至多只有一些辅助显示的设备，如倒车雷达。目前市面上大多数汽车都属于 L0。
- L1 级别的汽车可以提供一定的驾驶辅助，例如辅助巡航、辅助车道对准等。这类汽车的大部分控制仍然由驾驶员进行，系统只能提供小范围的辅助。现在不少汽车已经开始提供 L1 级别的自动驾驶辅助。
- L2 级别的汽车则已经可以自主控制加减速和方向盘，但程度较低，多数情况仍然需要人类驾驶员主动操作。车道内自动行驶、定速巡航等功能属于 L2 级别的功能。特斯拉 Autopilot 就属于 L2 级别。
- L3 级别是一个重要的分水岭。L3 级别的汽车已经基本达到了通常社会认为的自动驾驶——汽车通过传感器探测周围环境，自动决策，并控制车辆自主移动。L3 仍然有少部分情况不能处理，仍然需要人类驾驶员保持警惕，在紧急情况下接管车辆的控制权。奥迪的部分 A8L 车型便推出了 L3 级别的自动驾驶功能，但受制于不同国家和地区法律法规的不同，A8L 尚未覆盖全部自动驾驶功能。
- L4 级别的汽车不仅可以自动驾驶，还能处理紧急情况。这种时候，绝大多数情况下都不需要人类驾驶员。但是人类仍然可以选择手动调整到人工驾驶模式。沃尔沃和百度就正在合作研究自动驾驶出租车。
- L5 级别是最高级的自动驾驶，这种情况已经完全不需要人类驾驶员，方向盘、油门等常规驾驶装置也完全可以拆除。一切正常人类驾驶员可以到达的区域，L5 自动驾驶都可以自动完成。目前尚没有任何自动驾驶车辆能达到这一程度。

其中，L1 – L2 可以认为仅是自动驾驶辅助，人类驾驶员依然起主要作用，而 L3 – L4 是半自动驾驶，可以自动处理多数情况，L5 则是最高级的全自动驾驶 [1]。目前，多数自动驾驶的研究集中在 L2 – L4 之间。

2.1.2 自动驾驶的过程

依据文献 [17]，自动驾驶大体可以分为场景检测（环境理解）、决策、运动规划、车辆控制四个步骤。

其中，场景检测 (scenario detection) 或环境理解 (environment understanding) 是自动驾驶的基础，自动驾驶汽车将依靠各种传感器获取环境信息，并通过不同算法（通常是计算机视觉相关的神经网络）提取有用特征，检测周围车辆、行人的存在，并侦测交通标志、道路划线、交通信号灯等各种重要信息。语义分割的主要作用便在于环境检测，从相机拍摄得到的画面分割出不同的场景。

运动规划则是根据目的地和周围环境，规划安全且顺畅的行驶路线，并避开路上可能遇到的障碍物。决策则是做出关于是否变更车道、是否超越前车等具体的判断。这两者都是根据场景检测收集、提取的信息做出具体行动决策，是强化学习的主要应用步骤。

车辆控制是在计算机决定运行路径后，开始操纵汽车在路面上开始实际行驶的过程。

2.2 语义分割简介

语义分割 (semantic segmentation, 缩写 SS) 回答“图像的每一个像素点属于哪一个类别”的问题, 也就是辨析图像中各个像素点的“语义”, 其本质是对图像中每一个像素点进行多分类的问题。与目标检测 (object detection) 用矩形边界框 (boundary box, 缩写 bbox) 圈出物体不同, 语义分割回答每个物体属于哪一部分, 但是不区分同一类别的不同物体; 而实例分割 (instance segmentation) 则在语义分割的基础上进一步划分了同一类别的不同的物体, 但全景分割一般更注重目标而不注重背景, 会将背景 (如天空、房屋、路面) 都划为一类。三者的区别如图 1 所示。

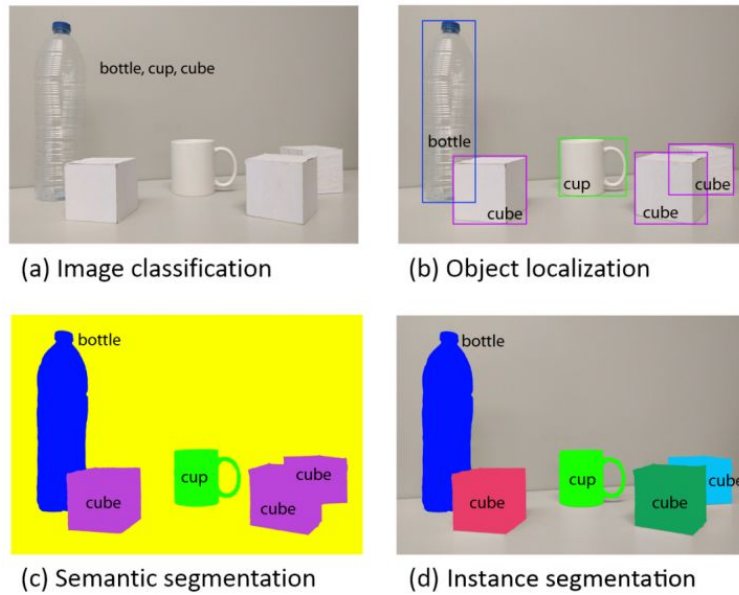


图 1: 目标检测 (b)、语义分割 (c)、实例分割 (d) 的区别。语义分割不区分三个不同的正方体, 而实例分割会给三个正方体标记上不同的颜色。

在自动驾驶中, 语义分割不仅包括传统的图像语义分割, 还包括点云语义分割 (semantic point cloud segmentation)。传统的图像语义分割是对相机拍摄的图像进行分析, 而点云语义分割则是对收集到的三维点云 (point cloud) 进行语义分割, 这种点云数据多是由激光雷达 (light detection and ranging, 缩写 LiDAR) 收集的, 它反映了一个物体的 3D 轮廓。点云是三维空间中的数据, 这意味着点云语义分割会比传统的二维图像分割更复杂。

自动驾驶中还有一类特殊的分割任务, 称为全景分割 (panoptic segmentation)。全景分割是语义分割和实例分割的结合, 它旨在像语义分割一样分辨不同的背景元素 (路面、天空、房屋等), 又结合实例分割的信息为不同实例打上不同的标签。实例分割同样包括传统图像实例分割和基于激光雷达的点云实例分割。

2.2.1 网络框架的介绍

本节主要讨论了以卷积神经网络 (Convolutional Neural Network, CNN) 为基础的语义分割网络框架发展, 以及对一些在该领域做出了重大贡献——FCN[43], Unet[56], GoogLeNet[60], ResNet[24], 以至于目前正被用作许多分割网络作为模块来衍生变形。尽管在过去二十多年里, 基于人工神经网络 (Artificial Neural Network, ANN) 的分割模型, 如浅层网络 (Reddick et al.; Kuntimad and Ranganath)、依靠超级像素分割图来产生像素级预测 (Couprie et al.), 是解决该领域的主要研究方向。直到 2014 年, Long, Shelhamer, and Darrell 发表的 FCN, 将分类网络最后的全连接层换成卷积层, 开启了用深度卷积网络来进行图像分割的大门。在本节中, 我们着重于介绍在端到端基于卷积神经网络的图像分割框架的发展史以及经典分割模型, 最后再简略介绍一下新兴的应用于点云语义分割的流行模型。

Long, Shelhamer, and Darrell 提出用于像素级分类的全卷积神经网络 FCN 是用 CNN 进行像素级分类的开山之作; Ronneberger, Fischer, and Brox 提出的 UNet 模型是一个经典的 Encoder-Decoder 结构, 包括一个收缩路径背景、扩展

路径实现精准定位。与图像识别 (He et al.) 和关键点检测 (Honari et al.) 所用的方法类似, Badrinarayanan, Kendall, and Cipolla 提出的 SegNet 在 Encoder-Decoder 分割网络中加入了跳转链接, 有效地解决了梯度消失问题, 提高了模型准确率。Yu, Koltun, and Funkhouser 提出 Dilated Convolution 用空洞卷积代替池化操作, 利用多尺度空洞卷积有效提取特征, 更好地结合上下文信息。Luc et al. 首次 GAN 思想用在语义分割中。Zhao et al. 提出的 PSPNet 利用空间金字塔池化操作, 将不同层次、感受野大小不同的 feature map 进行融合, 有效局部与全局多层次语义分割的特征。Chen et al. 提出了结合空洞卷积和特征金字塔优势的 DeepLabv3+ 模型, 在 Deeplabv3[11] 的基础上增加了 Decoder 模块, 细化分割结果。

下面我们将介绍几个常见的语义分割神经网络模型:

全卷积神经网络 (fully convolutional neural networks, 缩写 FCN) [43] 作为 CNN 卷积进行图像分割的开山之作, 完全改变了之前需要一个窗口来将语义分割任务转变为图片分类任务的概念。主要思想是将图像级分类任务中的全连接层换成卷积层, 开启了以 encoder-decoder 为结构的图像分割新纪元。网络结构如图所示:




图 2: Fully convolutional networks

后来人依据 FCN 的一些缺点例如信息损失大精度不高、样本量大、对细节不敏感等。提出了新的方法和模型, 例如 encoder-decoder 经典结构的 Unet 模型解决了小样本分割精度问题、Dilated Convolution 空洞卷积代替池化层得到更多细节信息提升精度、CRF 模型解决像素间关系问题。

残差神经网络 (residual neural network, 缩写 ResNet) 也是语义分割的常用网络之一。微软的 ResNet[24] 由于以 96.4% 的准确率赢得 ILSVRC-2016 而引人注目。除了这一事实, 该网络因其深度 (152 层) 和引入残差块而闻名 (下图 3)。残差块通过引入身份跳转连接来解决训练一个真正的深度架构的问题, 这样各层可以将它们的输入复制到下一层。这种方法背后的直观想法是, 它能确保下一层学习到新的、不同于输入已经编码的东西 (因为它同时得到了上一层的输出和未改变的输入)。此外, 这种连接有助于克服梯度消失的问题。




图 3: 残差块

在卷积神经网络中，浅层特征对感知细节部分感知能力强，能够提供分割目标在整个图像中的上下文语义信息也就是分割目标与它的环境之间的关系特征；深层特征感受域大，更易获得全局信息。U-Net 模型 [56] 利用 skip-connection 跳连结构有效地结合了 Encoder-Decoder 的 U 型结构中的浅层和深层特征，实现了不同尺度的特征融合和预测，提高模型准确性，被广泛使用在医学图像分割方面，并在 2015 年 ISBI 细胞追踪挑战赛取得优异成绩。




图 4: U-Net architecture

以往的 Deep Convolutional Neural Networks (DCNNs) 的最后一层不足以精确分割目标，Deeplab v1[12] 将深度神经网络与 Conditional Random Field (CRF) 相结合，采用空洞卷积，得到更加准确的细节分割，并在 PASCAL VOC-2012 的任务中更是获得了 SOTA，模型如下图 5所示：先用 DCNNs 得到粗略的分割特征图，通过双线性插值进行上采样后再用一个全连接的 CRF 细化分割结果。DeepLab v2[9] 在 DeepLab v1 的基础上增加了多尺度的空洞卷积 (ASPP) 一次性接受多个不同感受野信息，增加模型在多类别分割中的鲁棒性，在 PASCAL VOC 2012 数据集中取得了 79.7% 的 MIOU。DeepLab v3+ 不仅延用了 DeepLab v3 的模型改进 ASPP 模块、去掉 CRF 全连接层，还在此基础上增加了一个简单有效 Decoder 模块，优化了分割结果，在 PASCAL VOC 2012 数据集和 Cityscapes 数据集中分别取得了 89% 和 82.1% 的 MIOU。

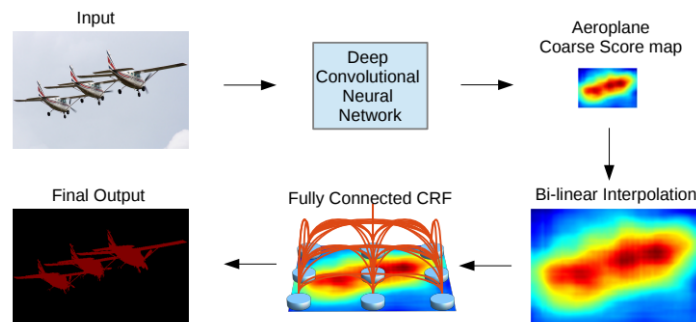


图 5: DeepLabv1 architecture

以上的几种网络都是基于传统二维图像语义分割的，但是在自动驾驶领域，与传统图像分割的一类突出的不同点，就是点云语义分割的大量应用。点云语义分割一般有两种方法，一种是将点云投影到二维再输入到二维图像分割网络，另

一种就是直接处理点云数据的网络。对于直接处理点云数据的网络，最经典的就是 PointNet [54]，它是第一个可以直接处理点云的网络。但是，PointNet 主要使用了 MLP 来提取特征，MLP 捕捉了全局信息，但不能重点关注局部信息。因此，文献 [53] 将 U-Net 和 PointNet 的特点结合起来，提出了 PointNet++，引入了类似于卷积层的 set abstraction 来实现降采样，并基于此构造了类似于 U-Net 的 Encoder-Decoder 结构。

2.2.2 语义分割常用数据集

对于刚接触该领域的新人来说掌握哪些是最优质的数据集和当前仍存在的挑战是非常重要的。上节对经典分割网络介绍中，不乏有使用这些数据集得到 SOTA 结果，本小节目的的在于对目前语义分割领域高质量数据集进行总结，以期每个新研究者能够快速熟悉和了解该领域的经典数据集。

PASCAL Visual Object Classes (VOC)。这项挑战包括一个有真实注释的图像数据集和五个不同的竞赛项目：分类、检测、分割、动作分类和人物布局。分割比赛的目标是预测每张测试图像的每个像素的物体类别。有 21 个类别，分为车辆、家庭、动物和其他：飞机、自行车、船、公共汽车、汽车、摩托车、火车、瓶子、椅子、餐桌、盆栽、沙发、电视/显示器、鸟、猫、牛、狗、马、绵羊和人。数据集分为两个子集：训练和验证，分别有 1464 和 1449 张图像。测试集是挑战赛的私有数据。这个数据集可以说是最受欢迎的语义分割的数据集，因此很多论文提出的模型方法都会用该数据集验证性能。

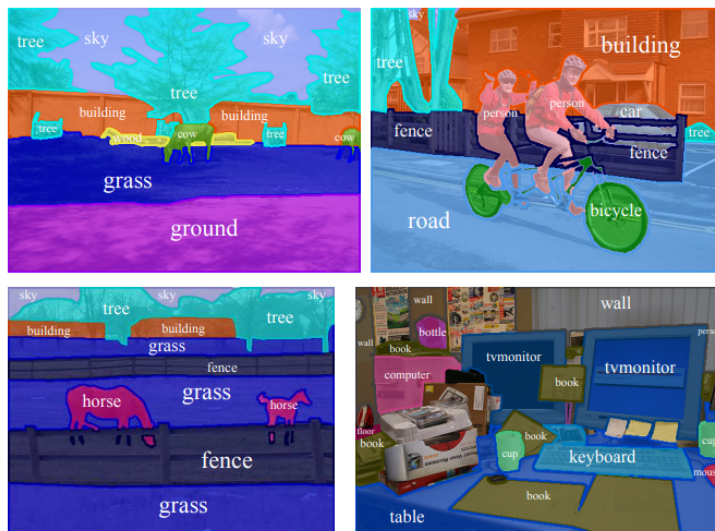


图 6: VOC dataset

Microsoft Common Objects in Context (COCO)。这是另一个图像识别、分割和说明的大规模数据集包含各种挑战，其中检测挑战与本领域最相关，因为它的一个部分是专注于分割。该挑战有 80 多个类别，提供了超过 82783 张图像用于训练，40504 张用于验证，其测试集包括超过 80000 张图像。特别是，测试集被分为四个不同的子集或分集。test-dev (20000 张图片) 用于额外的验证和调试，test-standard (20000 张图片) 是比赛的默认测试数据，用于比较最先进的方法，testchallenge (20000 张图片) 是提交给评估服务器时用于挑战的分割，test-reserve (20000 张图片) 是用于保护挑战中可能的过度拟合（如果一个方法被怀疑在测试数据上提交过多或训练过多，其结果将与保留分割比较）。由于其规模大，它的受欢迎程度和重要性自出现以来就急剧上升。

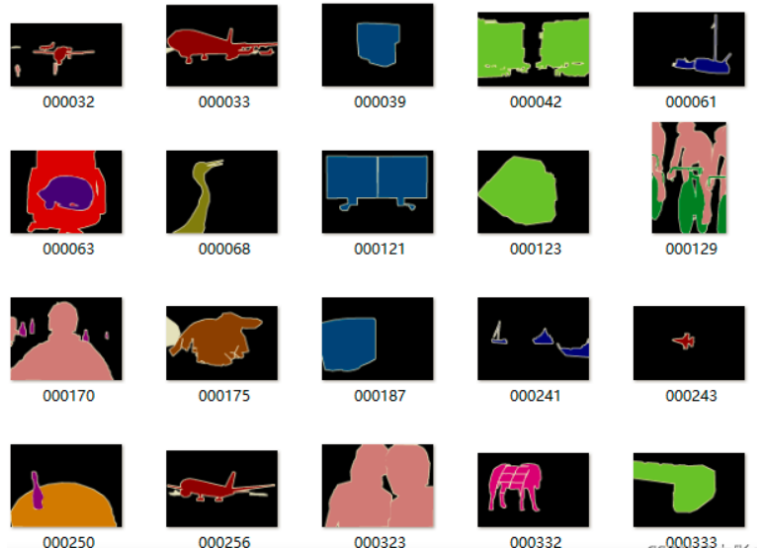


图 7: COCO dataset

Cityscapes 则是一个大规模的数据库，专注于城市街景的语义理解。它为 30 个类别提供语义、实例和密集的像素注释，这些类别分为 8 类（路面、人类、车辆、建筑、物体、自然、天空和空白）。该数据集包括大约 5000 张精细注释的图像和 20000 张粗略注释的图像。它最初是以视频形式记录的，因此这些帧被手动选择为具有以下特征：大量的动态物体、不同的场景布局 and 不同的背景。许多自动驾驶论文应用了 Cityscapes 作为基准数据集或主要数据集，用于检验语义分割神经网络的有效性，也常用于在各个论文之间比较性能优劣。



图 8: Cityscapes dataset

2.2.3 语义分割对自动驾驶的作用

语义分割（连同实例分割、全景分割）在自动驾驶的环境理解步骤起十分重要的作用。现在传感器收集数据的能力已经很强大，可以实时收集到海量的高清图像，还可以借助激光雷达直接收集到物体的三维数据。于是，如何处理这类数据，从其中提取有效信息就成为自动驾驶的一个重点。而语义分割的作用就是从图像中提取出各类元素的位置信息，例如其他车辆、车道、房屋建筑等，以为后序的运动决策等步骤提供信息。如果把自动驾驶汽车比作一个人，那么传感器就是“眼睛”，而语义分割就是“视觉中枢”。

2.3 强化学习简介

强化学习 (reinforcement learning, 缩写 RL) 是一门人工智能学科, 该学科研究如何让计算机代理 (agent) 学会通过与环境交互来获得奖励, 并学会怎样做出最佳决策。强化学习的发展史可以追溯到 20 世纪 50 年代, 但直到 1980 年代才开始真正兴起。1989 年, Richard S. Sutton 和 Andrew G. Barto 的书《*Reinforcement Learning: An Introduction*》首次将强化学习定义为一门独立的学科, 为今天的强化学习研究奠定了基础。Christopher Watkins 在 1989 年提出的 Q-Learning[16], 它是一种基于模型的强化学习的基础算法之一, 通过更新 Q 表来实现强化学习。Richard Sutton 和 Andrew Barto 在 1998 年提出了 SARSA 算法 [59], 该算法与 Q-Learning 类似, 但在更新 Q 表时使用了不同的计算方法。Volodymyr Mnih et al. 在 2015 年提出 DQN (Deep Q network) 算法 [49] 它利用深度神经网络来预测状态价值, 并通过存储和回放经验来解决稳定性问题。Volodymyr Mnih et al. 在 2016 年提出 A3C (Asynchronous Advantage Actor-Critic) [48], 该算法利用多个线程并行执行策略梯度计算来加速学习过程。

目前 RL 已成功应用于许多不同领域, 例如游戏 [49]、交通信号控制 [45]、水资源管理 [46]、健康信息学 [28]。并且在自动驾驶领域, RL 研究大部分使用 TORCS 或 Unity 来模拟现实路况, 对于良好驾驶的奖励信号明确处理, 对驾驶 (采取行动) 和计划 (在哪里驾驶) 之间的相互作用进行建模。

2.3.1 马尔可夫决策过程 (MDP)

大部分强化学习算法, 只有将问题抽象为马尔可夫决策过程 (Markov decision process, 缩写 MDP) 的才可保证算法的收敛性和效果。MDP 可以用一个五元组 $(S, A, P_{sa}, \gamma, R)$ 构成, 其中 S 是状态的集合、 A 是动作的集合、 γ 是折扣因子、 $r(s, a)$ 是奖励函数、 P_{sa} 是状态转移函数。

定义一个状态价值函数, 定义为从状态 s 出发遵循策略 π 能获得的期望回报:

$$V^\pi(s) = E[R(s_0) + \gamma R(s_1) + \gamma^2 R(s_2) + \dots | s_0 = s, \pi(s)]$$

目标是找到使累积奖励的预期最大化的策略:

$$\pi^*(s) = \arg \max_{\pi} \max_{\pi} E[V^\pi(s)]$$

找到一个由一组行动构成的策略 $\pi(s)$, 使得总回报最大化。

2.3.2 Q-learning

Q-learning 是解决 MDP 问题的常用算法之一。对每个状态 $s \in S$, action $a \in A$ 通过价值-动作函数 Q 得到: $S \times A \rightarrow \mathbb{R}$ 。基于 Bellman 方程得到:

$$Q_{t+1}(s, a) \leftarrow Q_t(s, a) + \alpha \left[r + \gamma \arg \max_{a'} Q_t(s', a') - Q_t(s, a) \right]$$

根据下一个状态 s' 中选取最大的 $Q_t(s', a')$ 值乘以 γ 减去 $Q_t(s, a)$ 估计再和旧 Q 表值相加来更新 Q 表。

2.3.3 Deep Q network(DQN)

深度强化学习结合了深度学习的结构和强化学习的思想, 但更侧重于强化学习, 解决的是决策问题, 借助神经网络强大的表征能力去拟合 Q-table 或直接拟合策略以解决状态-动作空间过大或连续状态-动作空间问题。

当状态是连续的, 或状态、选择数都非常多时, 不可能用 Q-table 记录穷举所有状态和选择, 于是一个常见的解决方法便是使用函数拟合 (function approximation) 的思想, 将传统 Q-learning 中的 Q 表用一个神经网络代替, 即改为一个输入状态 s , 输出各个行动 a 的 Q 估计值的神经网络。这样就得到了深度 Q 网络 (deep Q network, DQN) 算法。该神经网络目标是最小化 Q 值的均方误差:

$$l(w) = E \left[\left(r + \gamma \arg \max_{a'} Q_t(s', a', w) - Q_t(s, a, w) \right)^2 \right]$$

$$J(w) = \min_w l(w)$$

2.3.4 强化学习对自动驾驶的作用

强化学习的一个常见应用就是处理与环境交互的过程，十分契合自动驾驶汽车通过观测数据做出运动规划和决策，并最终反馈新信息的过程。沿用上一节的比喻，可以认为强化学习是大脑的运动中枢，负责思考判断根据当前场景汽车该做什么。

3 分割在自动驾驶中的应用

3.1 搜索方法

我们在 PubMed 搜索了语义分割相关的研究论文，搜索时间为 2023 年 2 月 4 日，搜索方法是：(AVS OR (((autonomous) OR (self-driving)) AND (cars OR vehicles))) AND (semantic segmentation)。搜索结果有 52 篇，除一篇以外（位于 2016 年），都分布于 2019 年及以后。截取 2019 年以来的 51 篇文献之后，首先剔除非研究文章，剩余 49 篇（PubMed 有少数综述错误地分类为了研究论文）；其次依据摘要和关键词剔除与语义分割和自动驾驶无关的论文，包括提及自动驾驶但不以自动驾驶为主题或重点的论文，剩余 33 篇；再通过浏览全文，继续剔除与自动驾驶无关的论文，剩余 28 篇。我们对语义分割的综述就围绕这 27 篇展开。搜索方法如图 9 所示。

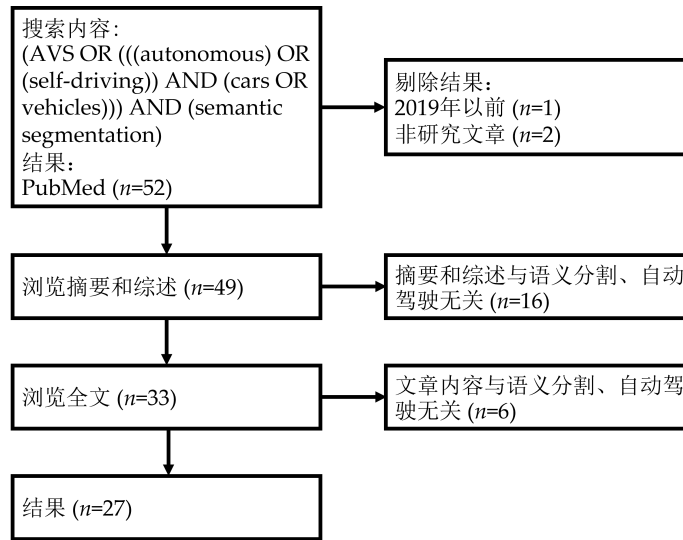


图 9: “语义分割在自动驾驶中的应用”论文搜索与筛选方法

尽管前面提及了语义分割、实例分割的区别，但是在计算机视觉和自动驾驶的应用中，因为涉及对周围环境的整体理解，往往不会单独使用实例分割。因此，以下的研究中把实例分割、全景分割均视为语义分割的一部分。同样地，点云分割也可以分为语义分割和实例分割，我们也认为点云实例分割是语义分割的一部分。

3.2 近年来的语义分割论文

这 27 篇论文主要的研究内容如下：

Atik and Duran[2] 使用球面投影方法，将坐标投影到球面上，再变换为二维图像。随后使用神经网络进行分割，该文中的网络综合 UNet 和 SegNet，用一个加法层连接两个网络的输出再进行分类。

Balado et al.[5] 使用 PointNet 研究点云语义分割, 分割激光雷达收集到的城市路面元素 (路面, 路堤, 护栏, 沟, 栅栏, 边界)。与人工神经网络 (ANN) 逐点分类比较后, 证明 PointNet 效果至少能与 ANN 持平, 某些类别效果比 ANN 更好。

Chang et al. [8] 的文章中, 受 U-Net 和 BiSeNet 启发, 创新设计了 dual encoder + self-attention 轻量网络, 引入 scSE 作为自注意机制。损失函数使用主交叉熵、互信息 (region mutual information)、辅助交叉熵之和, 其中辅助交叉熵只在训练过程中使用。最终准确率和 FPS 足够高, 同时参数数量相对较少, 可以用于实时检测。

Cho et al. [14] 考虑了 SLAM 地图系统, 将语义分割和概率不确定模型结合, 希望能自动识别周围景物。

Firkat et al. [19] 中研究了农村土路的语义分割问题。传统的语义分割方法在农村土路上表现不佳, 无法准确识别车道, 因此使用了 two-stages 方法对传统语义分割得到的粗略结果进一步加工, 得到更精确的结果。该结果可以用于土路的识别。

Florea et al. [20] 基于场景识别的多方法融合, 结合使用了图像全景分割和点云语义分割。语义分割使用了轻量 FCN。其中点云语义分割用于检测障碍物的存在, 文中融合了 4 个激光雷达以更精确地捕捉障碍物。

Huang et al. [30] 提出了一个新数据集: ApolloScape, 包含了点云信息, 录像, 同地点不同时间的场景, 道路场景标记。该数据集大于 Cityscapes 等许多已有数据集。同时, 发展了一种融合多传感器和分割算法的方法检验数据集的可行性。

Imad, Doukhi, and Lee[31] 使用迁移学习, 使得小数据量训练也可以得到很好的效果。论文中将 LiDAR 数据转化为鸟瞰图, 然后再训练。最终取得大于 30 FPS 的效果。论文中将一个传统的图像分类网络迁移学习至语义分割。论文中将预训练的 MobileNetv2 作为 encoder, 通过加入多层升维网络作为 decoder, 实现参数迁移。

Itu and Danescu [33] 结合图像语义分割, 提出一种简单的障碍物检测网络, 可以输出障碍物的实例分割、路面的语义分割和灭点。可以用于实时检测路面行驶时的障碍物。

Ivanovs et al.[34] 研究了图像数据增强。训练神经网络时, 在真实的 Cityscapes 数据中混入少量由 3D 软件 CARLA 模拟的场景进行数据增强。结果显示数据增强对语义分割准确率的提升无明显作用, 增强数据量对语义分割准确率也无明显作用。

Khan et al.[38] 提出了 LLDNet: 一个轻量的检测车道的网络。论文中指出很多网络只考虑良好路面, 没有考虑车道线不明显、人行道破裂、天气恶劣等情况, 因此提出了 LLDNet, 表明其可以在道路条件相对恶劣的地区 (如孟加拉国) 也达到较好的车道检测效果。

Kim et al. [39] 的研究中在语义分割后接上 FCN 以识别交通灯信号。结果表明效果优于传统的目标检测两阶段法, 可以成为检测小物体的一种网络。但是左箭头灯和黄灯由于出现时间短, 识别准确率仍有待提高。

Kolekar et al. [40] 使用了 inception U-Net 来对印度路面做语义分割, 同时第一次使用 Grad-CAM 来尝试解释神经网络的工作原理。Grad-CAM 可以输出一个网络识别一张图时的热力图, 说明此时网络主要关注图像中的哪些部分, 以此来解释神经网络的工作机制。

Lin et al.[42] 中提出了 FCN 只关注局部特征时可能部分区域分类错误的情况, 引入注意力机制提取网络的全局特征, 将全局特征和多个尺度的局部特征融合, 减少语义分割时部分区域分类错误的可能。

P et al. [50] 提出了 SemanticDepth, 研究当没有车道线时的车道语义分割, 只使用传统 RGB 作为输入。同时, 结合单目深度测量结构, 建立一个真实的 3D 点云。同时还能测量两个栏杆之间的宽度, 以确认车辆是否能够通过。

Petrovai and Nedeveschi. [51] 的文章中, 不同于以往的两阶段全景分割, 作者提出了一种直接的一阶段全景分割方法。网络在做语义分割的同时, 使用偏移回归和目标检测方法生成软注意力面具 (soft attention mask), 然后再应用于语义分割结果, 以达到实例分割的效果

Sáez et al. [61] 提出了一个适合处理鱼眼相机的实时语义分割方法。鱼眼相机的视角广, 但畸变比普通相机严重。同时, 论文中将普通数据集的照片经过变换近似作为鱼眼相机视角。

Sellat et al. [57] 提出了一个新的语义分割网络: 瓶颈残差网络, 这个网络结合了 FPN (特征金字塔网络)、可分离卷积, 达到较高准确率同时减少了计算量。

Tsai, Chang, and Li [64] 是语义分割与强化学习的结合。里面将语义分割作为强化学习收集信号的一部分。

Wang et al. [66] 提出了 OFRSNet 来产生无遮蔽的道路语义分割。即使道路被障碍物 (如车辆、路牌) 灯遮挡, 该网络也能准确识别出车道。

Xiang, Yang, and Wang [68] 的文章中提到, 普通的语义分割网络无法识别微小物体, 因此该论文引入偏振信息, 提出新的 EAFNet, 训练一个新的语义分割网络。结果它能很好地检测出小物体的存在以及高偏振特性的物体, 例如玻璃、汽车。

Yang et al. [69] 将语义信息和概率数据结合, 应用于自定位系统 (SLAM), 提高了定位准确率。论文提出了一种新的语义分割网络 Fast-SCNN, 并且将语义、几何、分布信息结合, 增强数据特征提取的效果, 最后好引入了概率数据结合来修正错误的结果。

Zhang, Zhang, and Liu[73] 提出了一种新的网络来解决鸟瞰图的道路识别问题。论文中运用变换方法将 RGB 图像和 LiDAR 点云变换为鸟瞰图, 同时通过鸟瞰图来识别道路, 提升准确率同时大幅降低了计算量。

Zhang et al.[74] 尝试使用合成数据来增加样本数量以提高语义分割网络的泛化能力。因此使用 Cityscapes 作为主数据集, 同时使用 GTA5 游戏截图作为增强数据。经过增强后结果优于部分其他研究。

3.3 结果分析

通过对 29 篇自动驾驶与分割论文的分析, 我们发现语义分割在自动驾驶应用广泛, 是自动驾驶场景识别与环境理解步骤的基础方法之一。但是, 不同论文对于语义分割在自动驾驶的应用的研究是多方面的, 研究的焦点集中在几个方面: 新场景或少见场景的识别、数据增强、点云语义分割的应用、改进或提升现有网络等等。

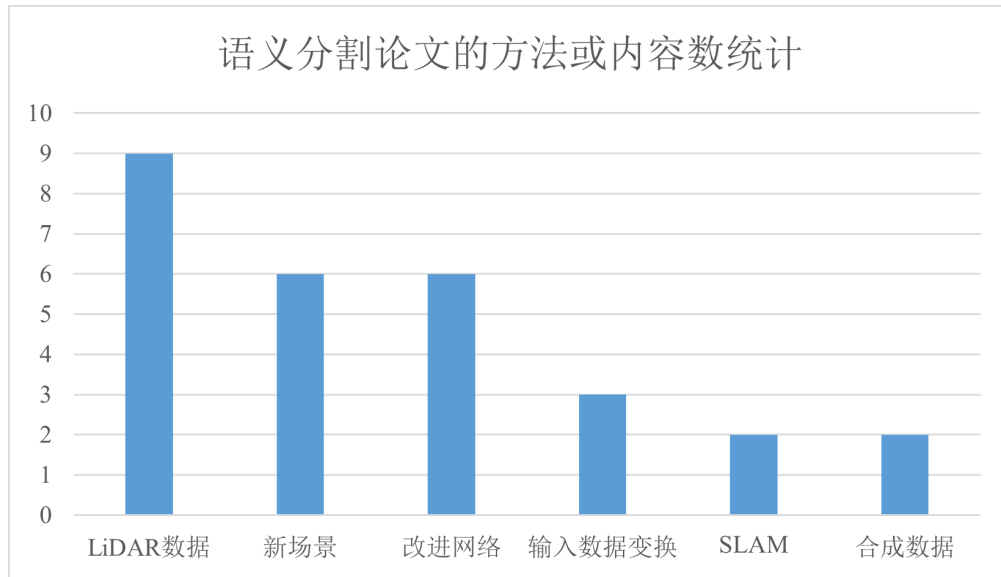


图 10: 语义分割的各个方法数的统计

如前所说, Cityscapes 在自动驾驶方面是一个非常常用的数据集, 许多自动驾驶的论文和网络都依据 Cityscapes 来训练。但该数据集专注于城市环境, 仍有许多场景无法覆盖。因此, 部分论文尝试收集新的数据并应用于新的场景, 如 Khan et al. 尝试对掉色、断续的车道线进行语义分割, Kim et al. 尝试更加准确地检测出路面上的交通灯, Xiang, Yang, and Wang 尝试在拥有小障碍物 (例如砖块、小动物) 遮挡路面时继续正确地分割语义, 而 Firkat et al. 则尝试对乡下的土路进行正确的语义分割。这些论文都集中于陌生场景或者少见情况的检测, 是对现有网络在某一种特殊情况下的改良, 如图 10 所示。

同时, 由于目前 3D 场景模拟软件 (例如 3D 游戏) 发展迅速, 也有一些研究尝试在训练数据中引入由这些软件产生的“合成数据”, 以此增加数据量。例如, Ivanovs et al. 和 Zhang et al. 就在 Cityscapes 数据集中混入了少量分别由 CARLA 和 GTA5 产生的画面 [34, 74]。但两者的结论并不一致, Ivanovs et al. 发现数据增强无明显现象, 而 Zhang et al. 却提高了准确率。

不少论文也使用了点云数据和点云语义分割。从使用了点云的论文来看, 点云的语义分割方法可以分为两种, 一种是



图 10: [38], [39], [68], [19] 分别研究的四种新场景

先将点云数据作某种投影或者变换 (通常是投影到球面), 再输入到传统的二维语义分割网络中; 另一种是直接由 PointNet 等直接接受点云作为输入的语义分割网络。

在激光雷达的应用中, 两篇论文尝试与 SLAM 地图系统结合 [14, 69]。同步定位与地图构建 (simultaneous localization and mapping, SLAM) 是一种解决定位问题的方案, 它可以使自动驾驶汽车通过收集的信息自动构建 3D 模型, 同时也可以让汽车确定自己在地图中已有的位置。Cho et al. 和 Yang et al. 都尝试通过激光雷达收集到的点云与 SLAM 结合, 使用激光雷达构建地图, 或者确定自己在地图中的位置并更新地图的细节。

同时, 也有论文实现了对网络结构的改进, 但大部分只是对成熟网络, 例如 U-net 和 PointNet 进行简单的修改, 或者是针对具体任务的特定性改进。同时, 不少论文关注了改进后网络的预测速度 (以 FPS 计), 以证明该模型的实时性达标, 可以用于具体的预测任务。

4 强化学习在自动驾驶中的应用

4.1 决策制定

2018 年的 ITSC 会议发表的自动驾驶变道决策论文 [26] 介绍了基于 DQN 自动生成通用决策函数的方法。大多数现有自动驾驶方法的一个共同问题是它们针对的是一个特定的驾驶案例——有些算法是为车辆在高速公路上行驶而设计, 有迎面而来的车辆在道路上行驶等, 使得模型不具有普适性。该文章提出更通用的方法来处理不同情况的驾驶状况模型, 同时该方法仍需要手动定义一些特征, 以使其规则和动作适应不同的驾驶情况。Q-learning 和 DQN 在某些条件下动作值函数会变得过高。进一步发展是 Double DQN 算法 [65], 第 i 次迭代的损失函数表达如下。该算法对每个变量使用两个估计器, 并将估计器的选择与其值解耦。

$$L_i(\theta_i) = \mathbb{E}_{\mathbf{M}} \left[\left(r + \gamma Q \left(s', \arg \max_a Q(s', a; \theta_i); \theta_i^- \right) - Q(s, a; \theta_i) \right)^2 \right].$$

该文用 Double DQN 算法分别在高速公路上, 迎面车的道路上两种情况下控制车辆, 如图 11, 应用两个代理: Agent1 和 Agent2, 其中 Agent1 仅控制车道变换决策, 速度由 IDM 自动控制; Agent2 控制换道决策和速度。使用相同状态输入 s, s 被定义为具有 27 个元素的向量, 其包含关于本车辆的速度、现有车道、8 辆周围车辆的状态的信息。该方法的主要优点在于其的通用性, 对于高速公路: 它可以产生比 IDM[63] 和 MOBIL[37] 模型组合更好的 Agent; 对于迎面车辆的交通的道路上的驾驶: 与之前方法相比 [25], 该方法不需要任何手工特征, 并且训练速度明显更快。缺点是该方法没有考虑到交叉十字路口这些情况下的自动驾驶车辆的安全性并且没有系统性地研究不同参数和网络架构之间的关系影响, 从而改善和加速学习过程。




图 11: 两种道路情况:(a) 高速公路案例的初始交通状况示例;(b) 二次超车情况示例

Yeping Hu et al.[29] 提出一种基于自适应策略的交互感知决策方法 (IDAS), 以解决自动驾驶在车辆合流场景下的决策问题。该方法在所有测试场景下都能实现零冲突, 但是不能在真实环境中保证安全性。

Yuchuan Fu et al.[22] 提出一种紧急制动自主决策策略, 并且充分考虑效率、准确性和乘客舒适性三个关键影响因素设计了多目标奖励函数。仿真结果表明该方案能够提升车辆在紧急情况下的制动性能, 保证车辆的安全性。

4.2 运动规划

运动规划是自动驾驶最重要部分之一, 其能够从环境中学习并直接根据感知做出决策而引起研究者的广泛关注。

Abdur et al.[18] 提出了基于深度学习的自动驾驶汽车自主导航和避障方法, 并将其用于城市环境中的模拟汽车。将摄像机和激光雷达采集数据的输入端, 运用深度学习提取数据特征, 再将特征输入 DQN 中得到下一步策略 (前进、向左向右、加速、刹车)。并且他们基于模拟设置, 设计出一款能够实时运算深度神经网络的汽车, 能够通过传感器数据融合实时运行 DQN 算法。本文设计了一种基于全连接 CNN 的深度学习网络来逼近 Q 函数, 该网络由 3 个卷积层和 4 个密集层组成 (如图 12, 网络由两种类型的数据输入: 前置摄像头图像 (80×80 的 RGB 图像) 和激光雷达数据 (80×80 的栅格图))。该文利用 Unity 游戏引擎设计了一个模拟城市环境, 由建筑物、树木、路灯和其他行驶在道路上的车辆组成。仿真实验表明, 神经网络经过训练后能够在环境中做出正确的决策, 实现汽车的自动驾驶。并在仿真实验基础上设计了一台能够实时运行 DQN 的汽车样机。然而, 该文章提出的方法并没有考虑到穿过道路行人以及一些突发事件时自动驾驶的安全性。

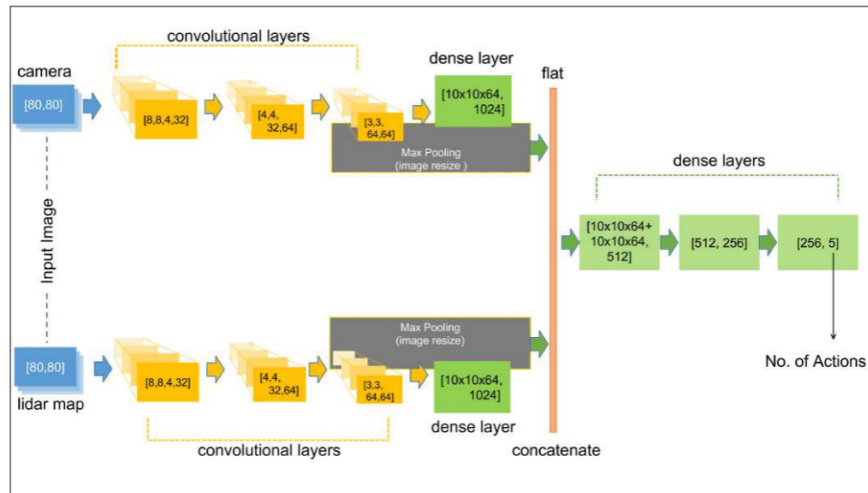


图 12: Abdur et al.Network architecture

DQN 作为一种非常流行的强化学习方法, 在自动驾驶领域取得了很大的进展, 但却很少运用全局道路信息来处理交叉路口拐弯、直行等运动决策规划。Long Chen et al.[13] 利用 DQN 让车辆在整个环境自动驾驶行进。摄像头图像输入 CNNs 和 LSTM 提取时空特征和方向导航信息, 再将特征和 reward 送到条件 DQN 网络, 通过设计的模糊逻辑算法解

耦输出运动指令,进而改变车辆的状态,如图 13。该方法在 CARLA 模拟器上进行了全面的实验,并且与先进的方法 DDQN[65] 和 A3C[48] 进行比较,实验表明,该方法具有较好的学习性能和驾驶稳定性。缺点在于没有考虑道路上存在的其他车辆以及行人、非机动车对决策的影响。

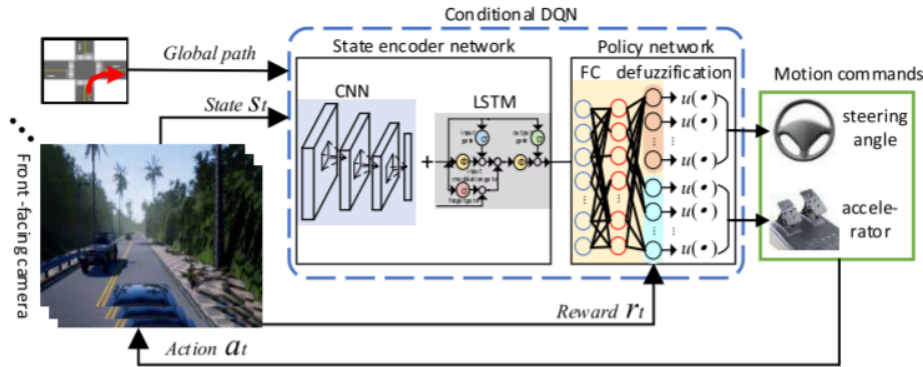


图 13: Chen et al. Network architecture

Mirchevska et al.[47] 提出一种基于 DRL 的仿真高速公路自主安全换道方法,能够在达到期望速度极限的高速公路场景下不会造成任何碰撞,并且在不同场景下表现出较好的泛化性。以下是 [70] 关于近年来运动规划相关文献的总结:

| 运动规划 | Algorithm | State | Action | Reward |
|----------------------------------|--------------------|-------------------------------------|--|---|
| Hoel, Wolff, and Laine[26] | DQN | Vehicle & relative states | $A = \{ \text{Lane change, Acc., Brake} \}$ | $R\{+ : \text{Efficiency, Comfort, Safety} \}$ |
| Bansal, Krizhevsky, and Ogale[6] | Imitation learning | Traffic light/dynamic object states | $A = \{ \text{Driving trajectory} \}$ | 9 training losses |
| Isele, Nakhaei, and Fujimura[32] | Classical RL | Local state | $A = \{ \text{Safe driving decision} \}$ | $R\{+ : \text{Safety} \}$ |
| Ye, Zhang, and Sun [71] | DDPG | Vehicle & relative states | $A = \{ \text{Lane change decision} \}$ | $R\{+ : \text{Efficiency, Comfort, Safety} \}$ |
| Shi et al. [58] | DQN | Vehicle relative states | $A = \{ \text{Lane change decision} \}$ | Hand-Crafted $R(s_t, a_t)$ |
| Bouton et al. [7] | Q-learning | Vehicle & agent states | $A = \{ \text{Strategic maneuvers} \}$ | $R\{+ : \text{Goal, Efficiency}; - : \text{Collision} \}$ |
| Ye et al. [70] | PPO | Vehicle & relative states | $A = \{ \text{Lane change decision, Car following} \}$ | $R\{+ : \text{Efficiency, Comfort, Safety} \}$ |

4.3 车辆控制

在自动驾驶领域里,早期有对端到端驾驶的研究 [52][4],但是大趋势仍然是使用感知-规划-控制范式。端到端驾驶受现代深度学习发展和算法限制,发展地非常缓慢。受异步强化学习的启发, Maximilian Jaritz et al.[35] 提出一种端到端驾驶方法,无需进行目标识别、语义分割感知步骤,仅在 Asynchronous Actor Critic (A3C) 框架中使用前向摄像头的 RGB 图像以及上一次迭代的 reward,让智能体在几款各种道路模式(雪、山丘、海岸)的赛车游戏 World Rally Championship 6(WRC6) 中进行端到端的训练,并且该方法具有一定的泛化性,可处理模拟中迎面而来的汽车。WRC6 游戏环境复杂,具有逼真的视觉效果,在 29.6 公里的训练跑道上有各种各样的外观、物理特性和道路布局。该文章在 WRC6 比赛环境中训练端到端驾驶,如图 14。仅使用 84×84 的前视图图像和速度最佳控制命令(转向、减速、加速、手刹)输入状态,让智能体在很少发生事故的情况下进行急转弯。该方法的缺点在于,端到端自动驾驶仍然处于早期阶段,尽管本文在拉力赛中已经表现了较好的泛化能力,但没有解决到同行车辆、非机动车、行人以及一些道路障碍物带来的冲突处理,端到端驾驶仍具有挑战性。

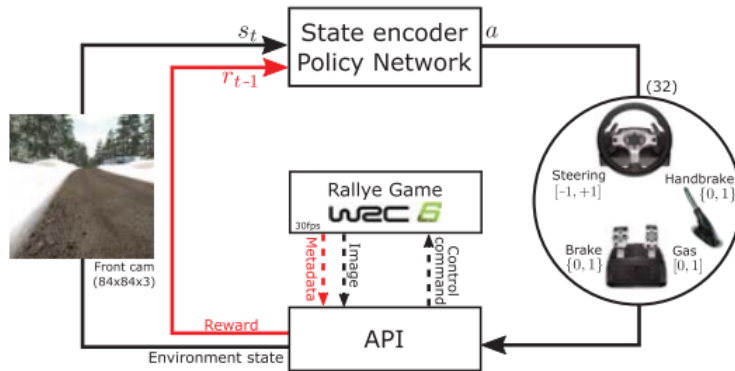


图 14: Maximilian et al. Network architecture

2019 年 Andreas et al.[21] 提出一种基于 DRL 的非线性控制器的通用设计方法，能够在 1.2ms 的极短运算时间内得到加速、转向的控制命令。该方法为当时第一个将泛化的模型方法成功运用到真实场景的自动驾驶汽车里的。

RL 目的是从实验中学习一个最优的行为策略，然而目前还没有一种 RL 算法能够处理像城市驾驶一样困难的任务。Marin et al.[62] 提出了一种新的技术，即 **implicit affordance**，以有效地利用 RL 来处理城市驾驶（车道保持、交通灯检测、行人和车辆避让以及处理有来车的交叉路口）。具体是将训练分为 2 个阶段（如图 15）：用编码器预测交通灯状态、车道中心距离等信息。再将编码器输出特征被用作 RL 状态，而不是原始图像，这将大大节省所需内存。该方法在 CARLA 挑战赛的“仅用照相机”赛道中表现 SOTA。缺点是在处理不同的天气条件下的感知算法性能有待提升，可能需要改进场景理解语义分割模型。

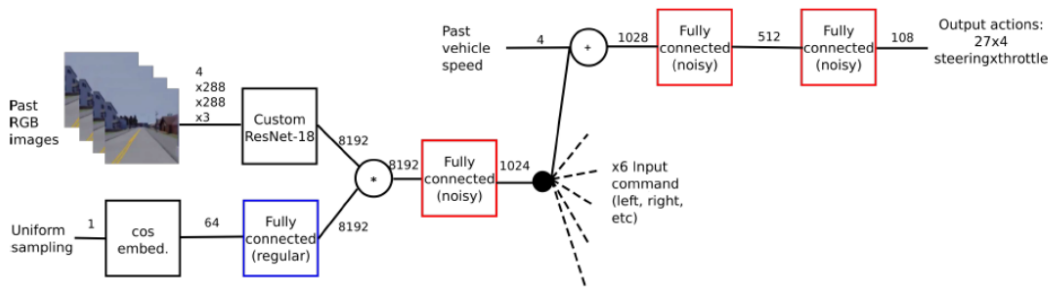


图 15: Marin et al. Network architecture

5 讨论

5.1 语义分割的讨论

现在，随着基于深度学习的计算机视觉算法的广泛流行，和许多成功的神经网络的提出、大型数据集的收集，语义分割也取得了巨大进展，成为了自动驾驶汽车在环境收集步骤的一个重要过程。语义分割中，现有多数研究都基于现有成熟的网络，对现有网络的改动很少。而新传感器、新场景、多传感器信息综合成为现有研究的重点。

自动驾驶汽车使用的传感器主要是相机和激光雷达，这两者收集到的数据并不一样——相机通常是彩色相机，可以收集到 RGB 三通道的信息，但收集到的图像是二维的；激光雷达则只能收集到周围固体的三维轮廓，但却不能收集到彩色信息，且对玻璃等镜面反射物体的识别效果很弱。文献 [61] 中便考虑了鱼眼相机。

如何将相机和激光雷达的信息综合，也是现在研究的热点之一。

新场景的研究和 Cityscape 数据集密切相关。如前所述, 这个数据集收集的主要是城市和街景的数据, 因为现在自动驾驶主要应用于城市, 所以这个数据集可以满足大部分城市的自动驾驶场景。不过, 通过这个数据集训练得到的语义分割只满足了一部分场景, 泛化能力还不足, 因此不少文章也提供了对特殊场景的语义分割方法补充 [38, 39, 68, 19]。不过可以看出, 这些文章都集中于单个场景的强化, 且部分文章都对网络结构做了改进, 因此这种改进并不是通用的。这样一个个单独的研究仍然并没有办法很好地整合在一起, 需要更进一步地研究来涵盖这一些现象。

不少研究也尝试引入虚拟合成数据来增加数据, 例如前文提到的 [34, 74]。但是两者使用的合成清晰度完全不同, CARLA 的画面相对粗糙一些, 而 GTA5 的画面则相对贴近现实。不同清晰度, 甚至不同的渲染引擎、不同的合成画面对数据增强效果带来的影响也是值得考虑的一个现象。另外, 研究发现, 往神经网络中注入人眼无法分辨的小噪声时也可以引起神经网络预测结果的不同, 而虚拟合成画面的差别则更加明显, 这种差别的具体影响也是值得进一步研究的。



图 15: CARLA (左) 和 GTA5 (右) 的画面, 可以看出清晰度、真实感的差别

5.2 强化学习的讨论

自动驾驶的广泛应用并非迫在眉睫, 但可以在一定程度上预防交通事故、缓解交通事故, 减少分心、酒后驾驶和超速等人类错误行为造成的社会损失。由于出色的深度感知、决策能力, 深度强化学习 (DRL) 被广泛应用于自动驾驶研究中。但目前大多数学者的研究仅是基于模拟环境, 例如 Unity、TORCS 和一些仿真游戏比赛进行智能体训练, 这使算法不具有泛化性和安全性。例如, 在高速公路性能较好的智能体在城市环境中表现可能不尽人意。同时天气条件、季节、交警指挥手势、突然闯入的行人等也会产生类似的问题, 即自动驾驶研究不能保证在所有场景下测试系统, 使其泛化到其他可能的环境。

充分训练需要大量的数据和时间, 这是深度学习的主要缺点之一。较长的训练周期会在自动驾驶车辆设计中引起延迟和额外的成本, 具有潜在的危险性。同时现实世界有非常多变的场景, 这也对数据的收集造成了一定的难度。

5.3 现有问题和未来方向

短期来看, 如果人工智能领域没有其他的突破, 基于深度学习的语义分割和强化学习将继续是自动驾驶的重要研究方向。

5.3.1 可解释性与理解能力

正如很多机器学习领域的专家所谈到, 神经网络依然是一个黑箱, 其强大的拟合能力仍然缺乏数学上的解释。特别值得关注的一点就是, 深度学习容易被对抗攻击, 从而造成网络的错误。同为基于深度学习和强化学习训练的开源围棋人工智能 KataGo, 在最近被发现: 对局中 KataGo 取得优势之后, 会对围棋中大片区域“气”的判断产生严重失误, 而这个失误对于人类棋手却非常不能理解, 甚至初学围棋的新手都不可能犯下这个错误。一个专门为 KataGo 训练的对抗 AI 可以在对局中稳定地使 KataGo 触发这个失误, 从而战胜 KataGo [67]。类似的事情也发生在自动驾驶上: 研究者们尝试在限速 35 miles/h 的交通标志上贴了一小段黑色胶带, 在正常人类看来这个交通标志仍然是限速 35 miles/h, 只是数字的字体比较奇怪, 而特斯拉汽车的自动驾驶功能却会将它误检测为 85 miles/h, 从而开始加速 (如图 15)。这个原因

可能可以解释为：自动驾驶的交通标志识别模型在训练集中并未包含这种情况（将 3 的中间一划延长）。尽管这种新情况对人类是可以理解的，可是却让神经网络将 35 识别为 85 了。



图 15: 正常的限速牌（左）和贴了一小段黑胶带的限速牌（右）。特斯拉汽车会把在数字“3”中间贴了一小段黑胶带的限速牌误识别为 85 (miles / h)，从而开始加速

自动驾驶不同于以往的手写数字识别、人脸识别等功能，一旦人工智能的理解稍有出错，就可能产生巨大的安全隐患，甚至直接酿成交通事故。因此，自动驾驶对人工智能的泛化能力要求更高，甚至要求它能应对某些新情况。以上误识别在特斯拉相同车型的不同车辆间都可以触发，因此一旦这类漏洞被发现和利用，就会影响路上千千万万同车型自动驾驶汽车的安全。Kolekar et al. 从商业上提升顾客信任的角度，尝试引入 GRAD-CAM 来提高神经网络的可解释性，论文中其实只是输出了神经网络对特点输入图片重点关注哪一块的信息，实际上仍未对神经网络的原理作进一步的解释 [40]。

5.3.2 多车通讯协同

现有的研究大多针对单独一辆车的自动驾驶，这辆车会独自收集数据、独立做出路线规划和决策，而少有研究多辆车协作的自动驾驶。未来的自动驾驶系统其实不应该把交通工具看作一个个独立个体，而应该可以与大数据云计算连接。

Ahangar et al. 关注于自动驾驶车辆间的互相通信、自动驾驶车辆与路边设施的通信，综述了不同通信方法的发展和优缺点 [1]。随着大数据的高速发展，自动驾驶汽车、路端摄像头、传感器等设施的信息共享是必然趋势。这种通信将极大提升自动驾驶汽车的能力，提高交通通行效率，同时进一步降低交通事故率。

6 结论

本文查阅、总结了多篇语义分割和强化学习在自动驾驶应用的论文，总结了语义分割和强化学习在自动驾驶的主要应用，以及这些论文的主要研究方向、性能和不足点。如今有越来越多的研究者将目光投向现实世界的应用 [36][21]，无人驾驶已经取得了极大的技术进步，但自动驾驶有关安全性、稳健性、高效性等关键难题问题有待进一步地解决，期待无人驾驶技术早日迎接新的技术跃迁。

References

- [1] M. N. Ahangar et al. “A Survey of Autonomous Vehicles: Enabling Communication Technologies and Challenges”. In: *Sensors (Basel)* 21.3 (2021). Ahangar, M Nadeem Ahmed, Qasim Z Khan, Fahd A Hafeez, Maryam eng Review Switzerland 2021/01/27 Sensors (Basel). 2021 Jan 21;21(3). pii: s21030706. doi: 10.3390/s21030706. ISSN: 1424-8220 (Electronic) 1424-8220 (Linking). DOI: 10.3390/s21030706. URL: <https://www.ncbi.nlm.nih.gov/pubmed/33494191>.
- [2] M. E. Atik and Z. Duran. “An Efficient Ensemble Deep Learning Approach for Semantic Point Cloud Segmentation Based on 3D Geometric Features and Range Images”. In: *Sensors (Basel)* 22.16 (2022).
- [3] Vijay Badrinarayanan, Alex Kendall, and Roberto Cipolla. “Segnet: A deep convolutional encoder-decoder architecture for image segmentation”. In: *IEEE transactions on pattern analysis and machine intelligence* 39.12 (2017), pp. 2481–2495.
- [4] Max Bajracharya et al. “Autonomous off-road navigation with end-to-end learning for the LAGR program”. In: *Journal of Field Robotics* 26.1 (2009), pp. 3–25.
- [5] J. Balado et al. “Road Environment Semantic Segmentation with Deep Learning from MLS Point Cloud Data”. In: *Sensors (Basel)* 19.16 (2019).
- [6] Mayank Bansal, Alex Krizhevsky, and Abhijit Ogale. “Chauffeurnet: Learning to drive by imitating the best and synthesizing the worst”. In: *arXiv preprint arXiv:1812.03079* (2018).
- [7] Maxime Bouton et al. “Reinforcement learning with probabilistic guarantees for autonomous driving”. In: *arXiv preprint arXiv:1904.07189* (2019).
- [8] Y. B. Chang et al. “Real-Time Semantic Segmentation with Dual Encoder and Self-Attention Mechanism for Autonomous Driving”. In: *Sensors (Basel)* 21.23 (2021).
- [9] Liang-Chieh Chen et al. “Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs”. In: *IEEE transactions on pattern analysis and machine intelligence* 40.4 (2017), pp. 834–848.
- [10] Liang-Chieh Chen et al. “Encoder-decoder with atrous separable convolution for semantic image segmentation”. In: *Proceedings of the European conference on computer vision (ECCV)*. 2018, pp. 801–818.
- [11] Liang-Chieh Chen et al. “Rethinking atrous convolution for semantic image segmentation”. In: *arXiv preprint arXiv:1706.05587* (2017).
- [12] Liang-Chieh Chen et al. “Semantic image segmentation with deep convolutional nets and fully connected crfs”. In: *arXiv preprint arXiv:1412.7062* (2014).
- [13] Long Chen et al. “Conditional DQN-based motion planning with fuzzy logic for autonomous driving”. In: *IEEE Transactions on Intelligent Transportation Systems* 23.4 (2020), pp. 2966–2977.
- [14] S. Cho et al. “Semantic Point Cloud Mapping of LiDAR Based on Probabilistic Uncertainty Modeling for Autonomous Driving”. In: *Sensors (Basel)* 20.20 (2020).
- [15] Camille Couprie et al. “Indoor semantic segmentation using depth information”. In: *arXiv preprint arXiv:1301.3572* (2013).
- [16] Peter Dayan and CJCH Watkins. “Q-learning”. In: *Machine learning* 8.3 (1992), pp. 279–292.

- [17] Badr Ben Elallid et al. “A Comprehensive Survey on the Application of Deep and Reinforcement Learning Approaches in Autonomous Driving”. In: *Journal of King Saud University - Computer and Information Sciences* 34.9 (2022), pp. 7366–7390.
- [18] Abdur R Fayjie et al. “Driverless car: Autonomous driving using deep reinforcement learning in urban environment”. In: *2018 15th international conference on ubiquitous robots (ur)*. IEEE. 2018, pp. 896–901.
- [19] E. Firkat et al. “ARDformer: Agroforestry Road Detection for Autonomous Driving Using Hierarchical Transformer”. In: *Sensors (Basel)* 22.13 (2022).
- [20] H. Florea et al. “Enhanced Perception for Autonomous Driving Using Semantic and Geometric Data Fusion”. In: *Sensors (Basel)* 22.13 (2022).
- [21] Andreas Folkers, Matthias Rick, and Christof Büskens. “Controlling an autonomous vehicle with deep reinforcement learning”. In: *2019 IEEE Intelligent Vehicles Symposium (IV)*. IEEE. 2019, pp. 2025–2031.
- [22] Yuchuan Fu et al. “A decision-making strategy for vehicle autonomous braking in emergency via deep reinforcement learning”. In: *IEEE transactions on vehicular technology* 69.6 (2020), pp. 5876–5888.
- [23] Luiz G Galvao et al. “Pedestrian and vehicle detection in autonomous vehicle perception systems—A review”. In: *Sensors* 21.21 (2021), p. 7267.
- [24] Kaiming He et al. “Deep residual learning for image recognition”. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, pp. 770–778.
- [25] Carl-Johan Hoel, Mattias Wahde, and Krister Wolff. “An evolutionary approach to general-purpose automated speed and lane change behavior”. In: *2017 16th IEEE International Conference on Machine Learning and Applications (ICMLA)*. IEEE. 2017, pp. 743–748.
- [26] Carl-Johan Hoel, Krister Wolff, and Leo Laine. “Automated speed and lane change decision making using deep reinforcement learning”. In: *2018 21st International Conference on Intelligent Transportation Systems (ITSC)*. IEEE. 2018, pp. 2148–2155.
- [27] Sina Honari et al. “Recombinator networks: Learning coarse-to-fine feature aggregation”. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, pp. 5743–5752.
- [28] Xinyu Hu et al. “An interpretable health behavioral intervention policy for mobile device users”. In: *IBM journal of research and development* 62.1 (2018), pp. 4–1.
- [29] Yeping Hu et al. “Interaction-aware decision making with adaptive strategies under merging scenarios”. In: *2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE. 2019, pp. 151–158.
- [30] X. Huang et al. “The ApolloScape Open Dataset for Autonomous Driving and Its Application”. In: *IEEE Trans Pattern Anal Mach Intell* 42.10 (2020), pp. 2702–2719.
- [31] M. Imad, O. Doukhi, and D. J. Lee. “Transfer Learning Based Semantic Segmentation for 3D Object Detection from Point Cloud”. In: *Sensors (Basel)* 21.12 (2021).
- [32] David Isele, Alireza Nakhaei, and Kikuo Fujimura. “Safe reinforcement learning on autonomous vehicles”. In: *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE. 2018, pp. 1–6.

- [33] R. Itu and R. Danescu. “Part-Based Obstacle Detection Using a Multiple Output Neural Network”. In: *Sensors (Basel)* 22.12 (2022).
- [34] M. Ivanovs et al. “Improving Semantic Segmentation of Urban Scenes for Self-Driving Cars with Synthetic Images”. In: *Sensors (Basel)* 22.6 (2022). 1424-8220 Ivanovs, Maksims Orcid: 0000-0003-2477-7327 Ozols, Kaspars Orcid: 0000-0002-9009-7306 Dobrajs, Artis Orcid: 0000-0003-1094-2037 Kadikis, Roberts Orcid: 0000-0001-6845-4381 78319/ECSEL Joint Undertaking/ project No. 1.2.1.1/18/A/006 research No. 1.5/ERDF/ Journal Article Switzerland 2022/03/27 *Sensors (Basel)*. 2022 Mar 14;22(6):2252. doi: 10.3390/s22062252. ISSN: 1424-8220. DOI: 10.3390/s22062252. URL: https://mdpi-res.com/d/_attachment/sensors/sensors-22-02252/article_deploy/sensors-22-02252-v2.pdf?version=1647319518.
- [35] Maximilian Jaritz et al. “End-to-end race driving with deep reinforcement learning”. In: *2018 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE. 2018, pp. 2070–2075.
- [36] Alex Kendall et al. “Learning to drive in a day”. In: *2019 International Conference on Robotics and Automation (ICRA)*. IEEE. 2019, pp. 8248–8254.
- [37] Arne Kesting, Martin Treiber, and Dirk Helbing. “General lane-changing model MOBIL for car-following models”. In: *Transportation Research Record* 1999.1 (2007), pp. 86–94.
- [38] M. A. Khan et al. “LLDNet: A Lightweight Lane Detection Approach for Autonomous Cars Using Deep Learning”. In: *Sensors (Basel)* 22.15 (2022). 1424-8220 Khan, Md Al-Masrur Orcid: 0000-0002-1729-4071 Haque, Md Foysal Orcid: 0000-0003-0634-9783 Hasan, Kazi Rakib Orcid: 0000-0002-9967-1538 Alajmani, Samah H Baz, Mohammed Masud, Mehedi Orcid: 0000-0001-6019-7245 Nahid, Abdullah-Al Orcid: 0000-0003-2391-5767 TURSP-2020/239/This work was supported by Taif University Researchers Supporting Project number (TURSP-2020/239), Taif University, Taif, Saudi Arabia./ Journal Article Switzerland 2022/07/29 *Sensors (Basel)*. 2022 Jul 26;22(15):5595. doi: 10.3390/s22155595. ISSN: 1424-8220. DOI: 10.3390/s22155595. URL: https://mdpi-res.com/d/_attachment/sensors/sensors-22-05595/article_deploy/sensors-22-05595.pdf?version=1658850377.
- [39] H. K. Kim et al. “Traffic Light Recognition Based on Binary Semantic Segmentation Network”. In: *Sensors (Basel)* 19.7 (2019).
- [40] S. Kolekar et al. “Explainable AI in Scene Understanding for Autonomous Vehicles in Unstructured Traffic Environments on Indian Roads Using the Inception U-Net Model with Grad-CAM Visualization”. In: *Sensors (Basel)* 22.24 (2022).
- [41] G Kuntimad and Heggere S Ranganath. “Perfect image segmentation using pulse coupled neural networks”. In: *IEEE Transactions on Neural networks* 10.3 (1999), pp. 591–598.
- [42] C. Y. Lin et al. “Global-and-Local Context Network for Semantic Segmentation of Street View Images”. In: *Sensors (Basel)* 20.10 (2020).
- [43] Jonathan Long, Evan Shelhamer, and Trevor Darrell. “Fully convolutional networks for semantic segmentation”. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2015, pp. 3431–3440.
- [44] Pauline Luc et al. “Semantic segmentation using adversarial networks”. In: *arXiv preprint arXiv:1611.08408* (2016).

- [45] Patrick Mannion et al. “Multi-objective dynamic dispatch optimisation using multi-agent reinforcement learning”. In: *Proceedings of the 2016 International Conference on Autonomous Agents & Multiagent Systems*. 2016, pp. 1345–1346.
- [46] Karl Mason et al. “Applying multi-agent reinforcement learning to watershed management”. In: *Proceedings of the Adaptive and Learning Agents workshop (at AAMAS 2016)*. Vol. 8. 2016.
- [47] Branka Mirchevska et al. “High-level decision making for safe and reasonable autonomous lane changing using reinforcement learning”. In: *2018 21st International Conference on Intelligent Transportation Systems (ITSC)*. IEEE. 2018, pp. 2156–2162.
- [48] Volodymyr Mnih et al. “Asynchronous methods for deep reinforcement learning”. In: *International conference on machine learning*. PMLR. 2016, pp. 1928–1937.
- [49] Volodymyr Mnih et al. “Human-level control through deep reinforcement learning”. In: *nature* 518.7540 (2015), pp. 529–533.
- [50] R. Palafox P et al. “SemanticDepth: Fusing Semantic Segmentation and Monocular Depth Estimation for Enabling Autonomous Driving in Roads without Lane Lines”. In: *Sensors (Basel)* 19.14 (2019). ISSN: 1424-8220. DOI: 10.3390/s19143224. URL: https://mdpi-res.com/d_attachment/sensors/sensors-19-03224/article_deploy/sensors-19-03224.pdf?version=1563801012.
- [51] A. Petrovai and S. Nedevschi. “Fast Panoptic Segmentation with Soft Attention Embeddings”. In: *Sensors (Basel)* 22.3 (2022). ISSN: 1424-8220. DOI: 10.3390/s22030783. URL: https://mdpi-res.com/d_attachment/sensors/sensors-22-00783/article_deploy/sensors-22-00783-v3.pdf?version=1643111683.
- [52] Dean A Pomerleau. “Alvinn: An autonomous land vehicle in a neural network”. In: *Advances in neural information processing systems* 1 (1988).
- [53] Charles R Qi et al. “PointNet++: Deep Hierarchical Feature Learning on Point Sets in a Metric Space”. In: *arXiv preprint arXiv:1706.02413* (2017).
- [54] Charles R. Qi et al. “PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017.
- [55] Wilburn E Reddick et al. “Automated segmentation and classification of multispectral magnetic resonance images of brain using artificial neural networks”. In: *IEEE Transactions on medical imaging* 16.6 (1997), pp. 911–918.
- [56] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. “U-net: Convolutional networks for biomedical image segmentation”. In: *Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5–9, 2015, Proceedings, Part III* 18. Springer. 2015, pp. 234–241.
- [57] Q. Sellat et al. “Intelligent Semantic Segmentation for Self-Driving Vehicles Using Deep Learning”. In: *Comput Intell Neurosci* 2022 (2022). 1687-5273 Sellat, Qusay Bisoy, SukantKishoro Orcid: 0000-0002-2657-5799 Priyadarshini, Rojalina Orcid: 0000-0002-5481-5251 Vidyarthi, Ankit Orcid: 0000-0002-8026-4246 Kautish, Sandeep Orcid: 0000-0001-5120-5741 Barik, Rabindra K Orcid: 0000-0003-3086-3782 Journal Article United States 2022/01/28 Comput Intell Neurosci. 2022 Jan 17;2022:6390260. doi:

- 10.1155/2022/6390260. eCollection 2022., p. 6390260. ISSN: 1687-5265 (Print). DOI: 10.1155/2022/6390260. URL: <https://downloads.hindawi.com/journals/cin/2022/6390260.pdf>.
- [58] Tianyu Shi et al. “Driving decision and control for autonomous lane change based on deep reinforcement learning”. In: *arXiv preprint arXiv:1904.10171* (2019).
- [59] Richard S Sutton and Andrew G Barto. *Reinforcement learning: An introduction*. MIT press, 2018.
- [60] Christian Szegedy et al. “Going deeper with convolutions”. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2015, pp. 1–9.
- [61] Á Sáez et al. “Real-Time Semantic Segmentation for Fisheye Urban Driving Images Based on ERFNet”. In: *Sensors (Basel)* 19.3 (2019). 1424-8220 Sáez, Álvaro Orcid: 0000-0003-2606-470x Bergasa, Luis M Orcid: 0000-0002-0087-3077 López-Guillén, Elena Romera, Eduardo Tradacete, Miguel Gómez-Huélamo, Carlos Del Egidio, Javier TRA2015-70501-C2-1-R/Spanish MINECO/FEDER through the SmartElderlyCar project/ SPIP2017-02305/DGT through the SERMON project/ S2013/MIT-2748/RoboCity2030-III-CM project (Robótica aplicada a la mejora de la calidad de vida de los ciudadanos. fase III), funded by Programas de actividades I+D (CAM) and cofunded by EU Structural Fund./ Journal Article Switzerland 2019/01/30 *Sensors (Basel)*. 2019 Jan 25;19(3):503. doi: 10.3390/s19030503. ISSN: 1424-8220. DOI: 10.3390/s19030503. URL: https://mdpi-res.com/d_attachment/sensors/sensors-19-00503/article_deploy/sensors-19-00503-v2.pdf?version=1548929007.
- [62] Marin Toromanoff, Emilie Wirbel, and Fabien Moutarde. “End-to-end model-free reinforcement learning for urban driving using implicit affordances”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2020, pp. 7153–7162.
- [63] Martin Treiber, Ansgar Hennecke, and Dirk Helbing. “Congested traffic states in empirical observations and microscopic simulations”. In: *Physical review E* 62.2 (2000), p. 1805.
- [64] J. Tsai, C. C. Chang, and T. Li. “Autonomous Driving Control Based on the Technique of Semantic Segmentation”. In: *Sensors (Basel)* 23.2 (2023). 1424-8220 Tsai, Jichiang Chang, Che-Cheng Orcid: 0000-0002-7526-9990 Li, Tzu 109-2221-E-035-067-MY3/National Science and Technology Council, Taiwan, R.O.C./ Journal Article Switzerland 2023/01/22 *Sensors (Basel)*. 2023 Jan 12;23(2):895. doi: 10.3390/s23020895. ISSN: 1424-8220. DOI: 10.3390/s23020895. URL: https://mdpi-res.com/d_attachment/sensors/sensors-23-00895/article_deploy/sensors-23-00895.pdf?version=1673516793.
- [65] Hado Van Hasselt, Arthur Guez, and David Silver. “Deep reinforcement learning with double q-learning”. In: *Proceedings of the AAAI conference on artificial intelligence*. Vol. 30. 1. 2016.
- [66] K. Wang et al. “Occlusion-Free Road Segmentation Leveraging Semantics for Autonomous Vehicles”. In: *Sensors (Basel)* 19.21 (2019).
- [67] Tony Tong Wang et al. *Adversarial Policies Beat Superhuman Go AIs*. 2022. arXiv: 2211.00241 [cs.LG].
- [68] K. Xiang, K. Yang, and K. Wang. “Polarization-driven semantic segmentation via efficient attention-bridged fusion”. In: *Opt Express* 29.4 (2021), pp. 4802–4820.
- [69] K. Yang et al. “Accurate Location in Dynamic Traffic Environment Using Semantic Information and Probabilistic Data Association”. In: *Sensors (Basel)* 22.13 (2022).

- [70] Fei Ye et al. “A survey of deep reinforcement learning algorithms for motion planning and control of autonomous vehicles”. In: *2021 IEEE Intelligent Vehicles Symposium (IV)*. IEEE. 2021, pp. 1073–1080.
- [71] Yingjun Ye, Xiaohui Zhang, and Jian Sun. “Automated vehicle’ s behavior decision making using deep reinforcement learning and high-fidelity simulation environment”. In: *Transportation Research Part C: Emerging Technologies* 107 (2019), pp. 155–170.
- [72] Fisher Yu, Vladlen Koltun, and Thomas Funkhouser. “Dilated residual networks”. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017, pp. 472–480.
- [73] P. Zhang, M. Zhang, and J. Liu. “Real-Time HD Map Change Detection for Crowdsourcing Update Based on Mid-to-High-End Sensors”. In: *Sensors (Basel)* 21.7 (2021).
- [74] Y. Zhang et al. “A Curriculum Domain Adaptation Approach to the Semantic Segmentation of Urban Scenes”. In: *IEEE Trans Pattern Anal Mach Intell* 42.8 (2020), pp. 1823–1841.
- [75] Hengshuang Zhao et al. “Pyramid scene parsing network”. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017, pp. 2881–2890.